텍스트와 이미지는 따로 배워야 한다: 패션 추천에서 모달리티별 학습 후 점수 결합의 효과

김유환 · 김형우 · 김광석 (서강대학교)

요약

멀티모달 추천 모델은 텍스트에 의존하고 이미지를 거의 활용하지 못한다는 보고가 있다. 본 연구는 이것이 이미지 정보의 한계인지, 텍스트와 이미지를 한 모델로 함께 학습하는 방식의 한계인지를 묻는다. H&M 실구매 데이터에서 ID를 쓰지 않는 Two-Tower 모델로 이미지 사용 방식만 바꿔 비교하고, 가설을 실험 전에 등록한 뒤 결과를 보지 않은 테스트 주에서 검정했다. 두 임베딩을 이어 붙여 함께 학습한 모델은 텍스트만 쓴 모델보다 Recall@300이 13 ~ 14% 높았지만, 텍스트 · 이미지 모델을 따로 학습해 고객별로 표준화한 점수를 더하면 세 테스트 주 모두 약 39% 높았다. 이 결합은 모델 수를 맞춘 함께 학습 앙상블보다 +0.0080, 같은 모달리티 앙상블보다 +0.0165 높아 앙상블 효과로 설명되지 않았다. 또한 범용 대규모 사전학습 인코더면 충분했고, 이미지 기여는 구매 기록이 적은 상품에서 약 2배였으며, 강한 베이스라인의 마지막 20자리를 결합 후보로 바꾸면 세 주 모두 베이스라인을 넘었다. 한 모델 안에서 모달리티 균형을 조절하는 처방은 일관된 이득이 없었다.

1. 서론

멀티모달 추천은 상품의 이미지와 텍스트로 표현을 풍부하게 하고 신규 상품에도 대응하려 한다. 그러나 Ye 외 [1]는 멀티모달 추천 모델 14개에서 텍스트를 제거하면 성능이 크게 떨어지지만 이미지를 제거해도 대부분 영향이 작아, 모델이 텍스트에 지배되고 이미지는 거의 쓰이지 않는다고 보고했다. 일반 멀티모달 학습에서도 여러 모달리티를 함께 학습하면 배우기 쉬운 쪽이 학습을 장악해 나머지가 덜 학습되는 **모달리티 불균형**이 알려져 있고 [3, 4], 함께 학습한 모델이 가장 좋은 단일 모달 모델을 넘지 못하기도 한다 [2]. 따라서 추천에서 이미지가 덜 쓰이는 이유는 이미지 정보가 없어서가 아니라 **함께 학습하는 방식** 때문일 수 있다.

본 연구는 "텍스트와 함께 쓸 때 이미지를 어떻게 써야 추천 성능이 오르는가"를 묻는다. 같은 구조의 모델로 이미지 사용 방식만 바꿔 비교했고, 확증 가설은 실험 전에 등록해 결과를 보지 않은 테스트 주에서 검정했다. 기여는 다음과 같다.

1. 텍스트와 이미지를 **따로 학습해 점수를 결합**하면 함께 학습할 때보다 크게 나아지고(텍스트만 대비 +39% 대 +13%), 이 차이가 **모델 수 · 앙상블 효과로 설명되지 않음**을 사전 등록 검정으로 확인했다.
2. 이 결과가 **세 테스트 주**에서 같은 크기로 재현됐다.
3. 인코더 선택, 상품 구매 기록, 베이스라인과의 결합에서 이미지의 역할을 정리했고, 효과가 없었던 처방도 보고했다.

2. 관련 연구

Ye 외 [1]는 Amazon 데이터와 ResNet-50 · SBERT 특징에서 모달리티를 하나씩 제거해 기여를 측정하고, 텍스트가 배우기 쉬워 시각 신호를 덮는다고 해석했다. Wang 외 [2]는 단일 모달 모델이 멀티모달 모델보다 자주 낫다는 점을, Wu 외 [3]와 Du 외 [4]는 한 모달리티에 기대는 탐욕적 학습과 모달리티 게으름을 보고했다. Du 외는 단독 특징이 강하고 상호작용이 중요하지 않을 때 **모달리티별 모델을 따로 학습해 예측을 합치는 방식(UME)** 이 적합하다고 제안했다. 불균형 처방들을 비교한 벤치마크 [5]는 어느 방법도 모든 데이터에서 기준을 넘지 못했다고 보고했고, 추천에서는 단일 모달 교사 증류(CKD) [6]가 시각 채널 활용을 높였다고 보고했다. **UME는 [4]가 제안한 방법이며, 본 연구는 추천에서 그 효과를 통제된 대조와 사전 등록으로 확인한다.** 상품 ID 없이 콘텐츠만으로 ID 모델에 근접할 수 있다는 보고 [7]처럼, 본 연구도 신규 상품을 바로 추천할 수 있는 ID 없는 설정을 다룬다.

3. 방법

모델. ID 없는 Two-Tower 모델을 쓴다. 상품 타워는 콘텐츠 임베딩을, 고객 타워는 최근 구매한 상품 최대 50개의 입력 평균을 MLP(은닉 512, 출력 128)에 넣고, 정규화한 내적을 점수로 배치 내 softmax로 학습한다. 학습 표본은 주 단위로 만들어 각 주 이전의 구매만 이력으로 쓴다.

이미지 사용 방식 (그림 1). (a) **함께 학습:** 텍스트 · 이미지 임베딩(각 256차원)을 이어 붙여 한 모델로 학습한다. (b) **따로 학습 후 결합(UME):** 텍스트 모델과 이미지 모델을 따로 학습하고, 고객마다 전체 상품 점수를 각각 표준화(z)해 1:1로 더한 상위 300개를 추천한다. (c) **앙상블 대조:** 같은 모델 두 개(seed만 다름)를 (b)와 같이 결합한다. 함께 학습 × 2는 모델 수를 맞춘 비교 대상이고, 텍스트 × 2와 이미지 × 2는 모달리티 보완 없는 앙상블 효과를 보여 준다.

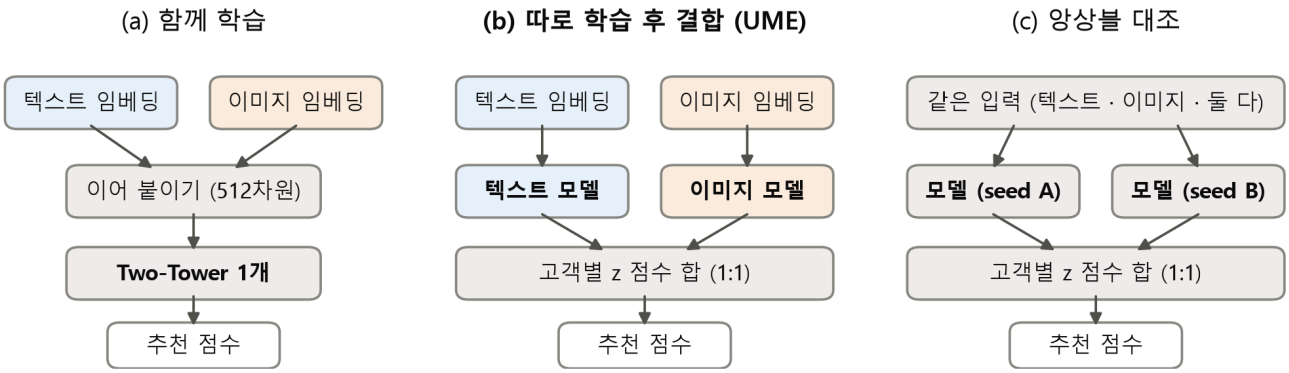


그림 1. 이미지 사용 방식. (a) 함께 학습, (b) 모달리티별로 따로 학습해 고객별 표준화 점수를 1:1로 결합, (c) 앙상블 효과를 분리하기 위한 같은 모델 두 개의 결합.

측정과 사전 등록. 콘텐츠 모델을 후보 생성 단계로 보고 고객별 평균 Recall@300(R)을 쓰며, 학습 데이터 판매 횟수로 기존(10회 이상) · 희소(1 ~ 9회) · 신규(테스트 주 첫 판매) 상품 구간을 나눈다. 차이는 고객 단위 짝지은 부트스트랩(1,000회)으로 구하며 결과는 seed 3개(또는 seed 쌍 3개)의 평균이다. 확증 가설은 비교 · 판정 기준과 함께 실험 전에 저장소에 커밋했고, 사전 등록 안의 검정 수만큼 본페로니 보정해 보정 구간의 하한이 0보다 크면 지지로 판정했다. 그 밖의 비교는 탐색적 결과로 95% 구간만 보고한다.

4. 실험 설정

H&M 구매 기록 31,788,324건 [10]에서 이미지가 있는 상품 53,232개와 학습 기간 구매 5회 이상 고객을 썼다. 학습 26주 · 검증 1주 · 테스트 1주로 나누되 테스트 주가 다른 세 분할을 썼다: main(2020-09-16 ~ 22, 고객 46,054명), s2(09-02 ~ 08, 50,904명), s4(08-19 ~ 25, 49,061명). 텍스트는 all-MiniLM-L6-v2(상품명 · 품목 · 색상 · 설명), 이미지는 Marqo-FashionSigLIP [8]을 기본으로 범용 SigLIP ViT-B/16, CLIP ViT-B/32(OpenAI · LAION-2B), FashionCLIP 2.0 [9], ResNet-50을 비교했고, 모두 PCA 256차원 + L2 정규화했다. 학습률 0.0005, 8에폭, 배치 2,048, 온도 0.05(검증 주로 선택)이며 L4 GPU에서 1회 약 20초다. 같은 조건의 재학습 22회가 모두 같은 추천을 내 학습이 결정적임을 확인했다.

표 1. 이미지 사용 방식별 Recall@300 (seed 3개 평균, 괄호는 텍스트만 대비). 이미지는 Marqo-FashionSigLIP, s4의 함께 학습 × 2는 미계산.

방식	모델 수	main	s2	s4
텍스트만	1	0.0928	0.0830	0.0849
이미지만	1	0.1010 (+9%)	0.0891 (+7%)	0.0926 (+9%)
함께 학습	1	0.1056 (+14%)	0.0935 (+13%)	0.0967 (+14%)
텍스트만 × 2 앙상블	2	0.1070	0.0955	0.0973
이미지만 × 2 앙상블	2	0.1112	0.0986	0.1013
함께 학습 × 2 앙상블	2	0.1213	0.1071	—
따로 학습 후 결합 (UME)	2	**0.1292 (+39%)**	**0.1151 (+39%)**	**0.1177 (+39%)**

5. 결과

5.1 함께 학습은 이미지를 충분히 쓰지 못한다. 이 데이터에서 이미지만 쓴 모델은 세 주 모두 텍스트만보다 7 ~ 9% 높아 이미지 자체의 정보는 충분했다. 그런데 함께 학습은 이미지만 대비 4 ~ 5%만 높았고, 텍스트 모델 두 개의 앙상블과 비슷했다(표 1). 학습에 포함된 마지막 주를 같은 모델로 다시 채점하면 함께 학습은 테스트 주보다 R이 0.059 높아 텍스트만(0.039) · 이미지만(0.035)보다 학습 데이터에 더 맞춰져 있었다(s4, 탐색).

5.2 따로 학습해 결합하면 크게 나아진다. UME는 세 주 모두 텍스트만 대비 약 +39%로 함께 학습의 약 3배였다(표 1). 새 테스트 주 s4의 사전 등록 검정에서 UME는 함께 학습보다 +0.0210(98.33% 구간 [+0.0197, +0.0224]) 높았다. 이후 사전 등록한 s2 검정에서 UME는 모델 수를 맞춘 함께 학습 × 2보다 **+0.0080** [+0.0066, +0.0096], 가장 강한 같은 모달리티 조합인 이미지 × 2보다 **+0.0165** [+0.0151, +0.0178] 높았고(98.33%), main에서도 +0.0079 · +0.0180으로 재현됐다. 서로 다른 이미지 인코더 두 개(Marqo + ResNet-50)의 결합도 0.1030으로 UME(0.1177)보다 낮았고(s4), 결합 가중치는 0.5 · 1 · 2 중 1:1이 s2 · main 모두 가장 높았다(탐색). 이득의 일부는 앙상블 효과지만 더 큰 부분은 모달리티를 따로 학습한 데서 오는 보완 효과다.

5.3 어떤 인코더를 쓸까. 출발점이 같은 범용 · 패션 적응 인코더 두 쌍에서 패션 적응은 이미지 기여를 바꾸지 않았다(사전 등록, 불지지). 반면 같은 CLIP ViT-B/32에서 사전학습 데이터를 OpenAI에서 LAION-2B로 바꾸면 이미지의 상대 기여도가 0.105에서 0.212로 약 2배였다(s2 사전 등록, +0.106 [+0.080, +0.131]). UME에서도 범용 SigLIP(0.1145)과 Marqo(0.1151)는 같고 ResNet-50(0.1038)은 낮았다(탐색).

5.4 어디에서 이미지가 중요한가. 희소 상품의 이미지 절대 기여도는 기존 상품의 약 2배였다(s2 사전 등록, +0.0129 [+0.0073, +0.0178]). UME의 이득은 주로 기존 상품에서 났고, 신규 상품에서는 함께 학습 × 2가 더 높았다(텍스트만 대비 +0.032 대 +0.024, 탐색).

5.5 강한 베이스라인과의 결합. 재구매 + 인기 베이스라인(B2, s2 · main 0.257)은 모든 콘텐츠 모델보다 높다. B2 앞 280개에 UME 후보 20개를 붙이면 s4에서 B2보다 **+0.0091** 높았고(사전 등록, 97.5% [+0.0081, +0.0101]) s2 · main에서도 +0.0027 · +0.0068로 세 주 모두 베이스라인을 넘었다. B2 앞 200개에 붙이는 사전 등록 비교에서도 UME 후보가 함께 학습 후보보다 +0.0097 [+0.0088, +0.0107] 높았고(s2, 98.33%), 280 + 20 구성에서도 세 주 모두 약 0.004 높았다. 20자리를 희소 · 신규 상품 전용으로 쓰면 전체는 B2보다 낮았지만(−0.0035) 신규 상품 재현율이 +0.033 올라 신상품 노출과의 트레이드오프를 보였다.

5.6 효과가 없거나 불안정한 처방. 한 모델 안에서 균형을 조절하는 처방은 일관된 이득이 없었다(표 2). 패턴 상품에서의 이미지 기여 증가와 상품 ID의 가림 효과도 지지되지 않았다. 학습 균형을 조절하기보다 **학습을 분리하는 것**이 훨씬 효과적이었다.

표 2. 한 모델 안의 처방 (함께 학습 대비 R 차이)

처방	테스트 주	차이	판정
텍스트 드롭아웃 0.1	main → s2	+0.0019 → −0.0010	재현 실패
이미지 드롭아웃 0.3	s2 → s4	+0.0023 → +0.0002	재현 실패
이미지 드롭아웃 (인코더 4종 평균)	s4	+0.0004 [−0.0002, +0.0010]	불지지
이미지 잡음 σ 0.06	s4	+0.0008 [−0.0005, +0.0020]	불지지
게이트 결합	main	+0.0005 [−0.0007, +0.0018]	불지지
우세 모달리티 억제	s2	−0.0015 [−0.0031, −0.0000]	불지지 (반대)

6. 결론 및 한계

텍스트와 이미지를 한 모델로 함께 학습하면 이미지가 더하는 정보의 상당 부분을 잃는다. 모달리티별로 따로 학습해 점수를 결합하면 텍스트만 대비 약 39% 높아지며, 이는 모델 수나 같은 모달리티 앙상블로 설명되지 않는다. 이미지가 거의 쓰이지 않는다는 관찰 [1]은 이미지 자체보다 함께 학습하는 방식의 한계를 반영할 수 있다. 실무적으로는 범용 대규모 사전학습 인코더를 쓰고, 모달리티별 모델을 따로 학습해 결합하며, 베이스라인의 마지막 일부 자리를 결합 후보로 채우기를 권한다.

한계. 데이터셋(H&M)과 모델 구조가 하나다. 함께 학습 모델의 규제를 따로 튜닝하지 않았고 결합 가중치는 세 값만 비교했다. Recall@300만 측정했고, 모델 단독 성능은 베이스라인보다 낮다. UME는 점수 계산과 상위 300개 선택(측정 중앙값 약 3ms)을 모델마다 해야 해 검색 지연이 최대 약 두 배로 늘 수 있다(추정; 타워 계산은 0.1 ~ 0.3ms). OpenAI · LAION 비교는 데이터 양과 구성이 함께 다르다. 코드, 사전 등록 파일과 모든 검정 결과(불지지 · 재현 실패 포함)는 저장소에 공개한다【미정: 링크】.

참고문헌

[1] Y. Ye 외, "Are Multimodal Embeddings Truly Beneficial for Recommendation? A Deep Dive into Whole vs. Individual Modalities," arXiv:2508.07399, 2025.

[2] W. Wang, D. Tran, M. Feiszli, "What Makes Training Multi-Modal Classification Networks Hard?," CVPR 2020.【확인 필요】

[3] N. Wu, S. Jastrzębski, K. Cho, K. J. Geras, "Characterizing and Overcoming the Greedy Nature of Learning in Multi-modal Deep Neural Networks," ICML 2022.【확인 필요】

[4] C. Du 외, "On Uni-Modal Feature Learning in Supervised Multi-Modal Learning," ICML 2023.

[5] S. Xu 외, "BalanceBenchmark: A Survey for Multimodal Imbalance Learning," arXiv:2502.10816, 2025.

[6] J. Zhang 외, "Modality-Balanced Learning for Multimedia Recommendation," ACM MM 2024.

[7] Z. Yuan 외, "Where to Go Next for Recommender Systems? ID- vs. Modality-based Recommender Models Revisited," SIGIR 2023.【확인 필요】

[8] Marqo, "Marqo-FashionSigLIP," Hugging Face, 2024.

[9] P. J. Chia 외, "FashionCLIP," Hugging Face.【확인 필요: 인용 형식】

[10] H&M Personalized Fashion Recommendations, Kaggle, 2022.【확인 필요: 이용 조건】