3성하이닉스 · 2026-10-21 · 초안 작성 김유환 · **팀 리뷰 요청** 근거: 실험기록.md (모든 수치), 선행연구조사_이미지활용도.md, 사전 등록 paper/configs/prereg_*.yaml 표시:【확인 필요】원문 확인 전 인용 · 【미정】 팀 결정 필요 · 분량 목표 3쪽(2단) · 그림 재생성: python paper/scripts/make_draft_figures.py 리뷰 요청 사항은 맨 아래 "리뷰 요청" 절에 정리했다.

텍스트와 이미지는 따로 배워야 한다: 패션 추천에서 모달리티별 학습 후 점수 결합의 효과

김유환 · 김형우 · 김광석 (소속【미정】)

요약

멀티모달 추천 모델은 텍스트에 의존하고 이미지를 거의 활용하지 못한다는 보고가 있다. 본 연구는 이 현상이 이미지 정보의 한계인지, 텍스트와 이미지를 한 모델로 함께 학습하는 방식의 한계인지를 묻는다. H&M 실구매 데이터에서 ID를 쓰지 않는 Two-Tower 모델로 이미지 사용 방식만 바꿔 비교하고, 가설을 실험 전에 등록한 뒤 결과를 보지 않은 테스트 주에서 검정했다. 텍스트와 이미지 임베딩을 이어 붙여 함께 학습한 모델은 텍스트만 쓴 모델보다 Recall@300이 13 ~ 14% 높았지만, 텍스트만 · 이미지만 쓰는 모델을 따로 학습해 고객별로 표준화한 점수를 더하면 세 개의 테스트 주에서 모두 약 39% 높았다. 이 결합은 모델 수를 맞춘 함께 학습 모델 두 개의 앙상블보다 +0.0080, 같은 모달리티 모델 두 개의 앙상블보다 +0.0165 높아 단순한 앙상블 효과로 설명되지 않았다. 이미지 인코더는 텍스트와 함께 대규모로 사전학습한 범용 모델이면 충분했고, 이미지의 기여는 구매 기록이 적은 상품에서 약 2배 컸으며, 강한 재구매 · 인기 베이스라인의 마지막 20자리를 결합 후보로 바꾸면 세 테스트 주 모두 베이스라인을 넘었다. 반면 한 모델 안에서 모달리티 균형을 조절하는 처방(모달리티 드롭아웃, 게이트 결합, 잡음 주입, 우세 모달리티 억제)은 일관된 이득을 주지 못했다.

1. 서론

상품의 이미지와 텍스트를 함께 쓰는 멀티모달 추천은 상품 표현을 풍부하게 하고, 구매 기록이 없는 신규 상품에도 대응하려는 목적을 가진다. 그러나 Ye 외 [1]는 멀티모달 추천 모델 14개에서 텍스트 임베딩을 제거하면 성능이 크게 떨어지는 반면 이미지 임베딩을 제거해도 대부분 영향이 작다는 점을 보이고, 모델이 텍스트에 지배되며 이미지는 거의 쓰이지 않는다고 보고했다.

일반 멀티모달 학습에서는 비슷한 현상이 모달리티 불균형으로 알려져 있다. 여러 모달리티를 하나의 목표로 함께 학습하면 배우기 쉬운 모달리티가 학습을 먼저 장악하고 나머지는 충분히 학습되지 않으며 [3, 4], 그 결과 함께 학습한 모델이 가장 좋은 단일 모달 모델을 넘지 못하기도 한다 [2]. 이 관점에서 보면, 추천에서 이미지가 덜 쓰이는 이유는 이미지에 쓸 만한 정보가 없어서가 아니라 **텍스트와 함께 학습되는 방식** 때문일 수 있다.

본 연구는 "텍스트와 함께 쓸 때 이미지를 어떻게 써야 추천 성능이 오르는가"를 묻는다. H&M 실구매 데이터에서 같은 구조의 모델로 이미지 사용 방식만 바꿔 비교했다. 결과에 맞춰 해석을 바꾸는 위험을 줄이기 위해 모든 확증 가설을 실험 전에 저장소에 등록했고, 결과를 본 뒤 세운 가설은 그 결과를 보지 않은 테스트 주에서 검정했다.

본 연구의 기여는 다음과 같다.

1. 텍스트와 이미지를 **따로 학습해 점수를 결합**하면 함께 학습할 때보다 크게 나아지며(텍스트만 대비 +39% 대 +13%), 이 차이가 **모델 수와 앙상블 효과로 설명되지 않음**을 사전 등록한 검정으로 확인했다.
2. 이 결과가 **세 개의 테스트 주**에서 같은 크기로 재현됨을 보였다.
3. 이미지 인코더 선택, 상품의 구매 기록, 강한 단순 베이스라인과의 결합에서 이미지의 역할을 정리했다.
4. 한 모델 안에서 모달리티 균형을 맞추려는 처방들이 일관된 이득을 주지 못했다는 **부정 결과**를 함께 보고했다.

2. 관련 연구

텍스트 지배. Ye 외 [1]는 Amazon Baby · Sports · Clothing 데이터와 ResNet-50 · SBERT 특징에서 모달리티를 하나씩 제거해 기여를 측정했고, 텍스트 신호가 배우기 쉬워 시각 신호를 덮는다고 해석했다.

모달리티 불균형. Wang 외 [2]는 가장 좋은 단일 모달 모델이 멀티모달 모델보다 자주 낫다는 점을 보이고 모달리티별 손실 가중을 제안했다. Wu 외 [3]는 한 모달리티에 기대는 탐욕적 학습을, Du 외 [4]는 각 모달리티의 단독 특징이 덜 학습되는 모달리티 게으름을 보고했다. Du 외는 단독 특징이 강하고 모달리티 간 상호작용이 중요하지 않을 때 **모달리티별 모델을 따로 학습해 예측을 합치는 방식(Uni-Modal Ensemble, UME)** 이 적합하다고 제안했다. 이 계열 방법을 같은 조건에서 비교한 벤치마크 [5]는 어느 방법도 모든 데이터에서 기준을 넘지 못했다고 보고했다. 추천에서는 단일 모달 교사로 멀티모달 학생을 증류하는 CKD [6]가 시각 채널의 활용을 높였다고 보고했다. **UME 자체는 [4]가 제안한 방법이며, 본 연구는 새 방법을 제안하기보다 추천에서 그 효과를 통제된 대조와 사전 등록으로 확인한다.**

콘텐츠 기반 추천. 상품 ID 없이 콘텐츠 인코더만으로 ID 기반 모델에 근접할 수 있다는 보고가 있다 [7]. 본 연구도 상품 ID를 쓰지 않아 신규 상품을 바로 추천할 수 있는 설정을 다룬다.

3. 방법

모델. ID를 쓰지 않는 Two-Tower 모델을 쓴다. 상품 타워는 상품의 콘텐츠 임베딩을 MLP(은닉 512, 출력 128)에 입력한다.

고객 타워는 고객이 최근 구매한 서로 다른 상품 최대 50개의 상품 입력 평균을 같은 구조의 MLP에 입력한다. 두 출력을 정규화한 내적을 점수로, 배치 안의 다른 상품을 부정 샘플로 하는 softmax로 학습한다. 학습 표본은 주 단위로 만들며, 각 주의 구매를 정답으로 하고 그 주 이전의 구매만 이력으로 써서 미래 정보가 섞이지 않게 한다.

이미지 사용 방식. 세 방식의 구조는 그림 1과 같다.

- **함께 학습:** 텍스트와 이미지 임베딩을 이어 붙여(각 256차원 → 512차원) 한 모델로 학습한다.
- **따로 학습 후 결합(UME):** 텍스트만 쓰는 모델과 이미지만 쓰는 모델을 따로 학습한다. 추천할 때 고객마다 전체 상품에 대한 두 모델의 점수를 각각 표준화(z)해 더하고 상위 300개를 고른다. 두 점수의 가중치는 1:1로 고정했다.
- **앙상블 대조:** 같은 방식으로 서로 다른 seed의 같은 모델 두 개를 결합한다. 함께 학습 × 2는 모델 수를 맞춘 비교 대상이고, 텍스트만 × 2와 이미지만 × 2는 모달리티 보완 없이 앙상블만의 효과를 보여 준다.

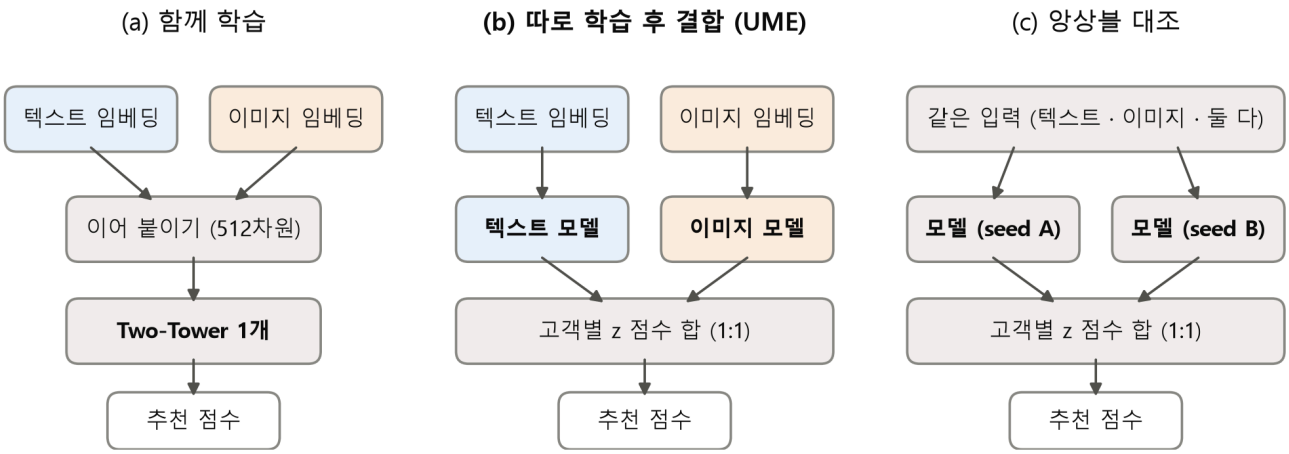


그림 1. 이미지 사용 방식. (a) 텍스트와 이미지 임베딩을 이어 붙여 한 모델로 학습한다. (b) 텍스트 모델과 이미지 모델을 따로 학습하고, 고객마다 전체 상품 점수를 표준화해 1:1로 더한다. (c) 앙상블 효과를 분리하기 위한 대조로, 같은 입력의 모델 두 개(seed만 다름)를 (b)와 같은 방식으로 결합한다.

측정. 고객별 평균 Recall@300(R)을 쓴다. 학습 데이터 판매 횟수에 따라 기존 상품(10회 이상), 희소 상품(1 ~ 9회), 신규 상품(테스트 주에 처음 판매)으로 나눠 볼 때는 해당 구간의 구매로만 계산한다. 차이의 불확실성은 고객 단위 짝지은 부트스트랩(1,000회)으로 구하며, 모든 조건이 같은 재표집을 공유한다. 결과는 학습 seed 3개(42, 43, 44) 또는 seed 쌍 3개의 평균이다.

사전 등록. 확증 가설은 측정값 · 비교 · 판정 기준과 함께 실험 전에 저장소에 커밋했다. 한 사전 등록 안의 검정 수만큼 본페로니 보정을 적용해, 보정된 구간(예: 검정 3개면 98.33%)의 하한이 0보다 크면 지지로 판정했다. 결과를 본 뒤 세운 가설은 그 결과를 보지 않은 테스트 주에서 검정했고, 그 밖의 비교는 탐색적 결과로 구분해 보정 없이 95% 구간만 보고한다.

4. 실험 설정

데이터. H&M 구매 기록 31,788,324건(2018-09-20 ~ 2020-09-22) [10]에서 이미지가 있는 상품 53,232개와 학습 기간 구매가 5회 이상인 고객을 대상으로 했다. 학습 26주 · 검증 1주 · 테스트 1주로 나누되 테스트 주를 바꾼 세 분할을 썼다: main(2020-09-16 ~ 22, 고객 46,054명 · 구매 150,415건), s2(09-02 ~ 08, 50,904명 · 168,897건), s4(08-19 ~ 25, 49,061명 · 164,954건).

인코더. 텍스트는 all-MiniLM-L6-v2로 상품명 · 품목 · 색상 · 설명을 임베딩했다. 이미지는 Marqo-FashionSigLIP [8]을 기본으로 하고, 같은 구조의 범용 SigLIP ViT-B/16(WebLI), CLIP ViT-B/32(OpenAI · LAION-2B), FashionCLIP 2.0 [9], ResNet-50(ImageNet)을 비교했다. 모든 임베딩은 PCA로 256차원으로 줄인 뒤 L2 정규화했다.

학습. 학습률 0.0005, 8에폭, 배치 2,048, 온도 0.05이며 검증 주로 선택했다. NVIDIA L4 GPU 1장에서 1회 학습은 약 20초다. 학습은 결정적이어서, 같은 조건을 다시 학습한 22개 실행이 모두 기존 실행과 같은 추천을 냈다.

5. 결과

표 1. 이미지 사용 방식별 Recall@300 (seed 3개 평균, 괄호는 텍스트만 대비)

방식	모델 수	main	s2	s4
텍스트만	1	0.0928	0.0830	0.0849
이미지만	1	0.1010 (+9%)	0.0891 (+7%)	0.0926 (+9%)
함께 학습	1	0.1056 (+14%)	0.0935 (+13%)	0.0967 (+14%)
텍스트만 × 2 앙상블	2	0.1070	0.0955	0.0973
이미지만 × 2 앙상블	2	0.1112	0.0986	0.1013
함께 학습 × 2 앙상블	2	0.1213	0.1071	—
따로 학습 후 결합 (UME)	2	**0.1292 (+39%)**	**0.1151 (+39%)**	**0.1177 (+39%)**

이미지는 Marqo-FashionSigLIP. s4의 함께 학습 × 2는 벡터를 저장하지 않아 계산하지 않았다.

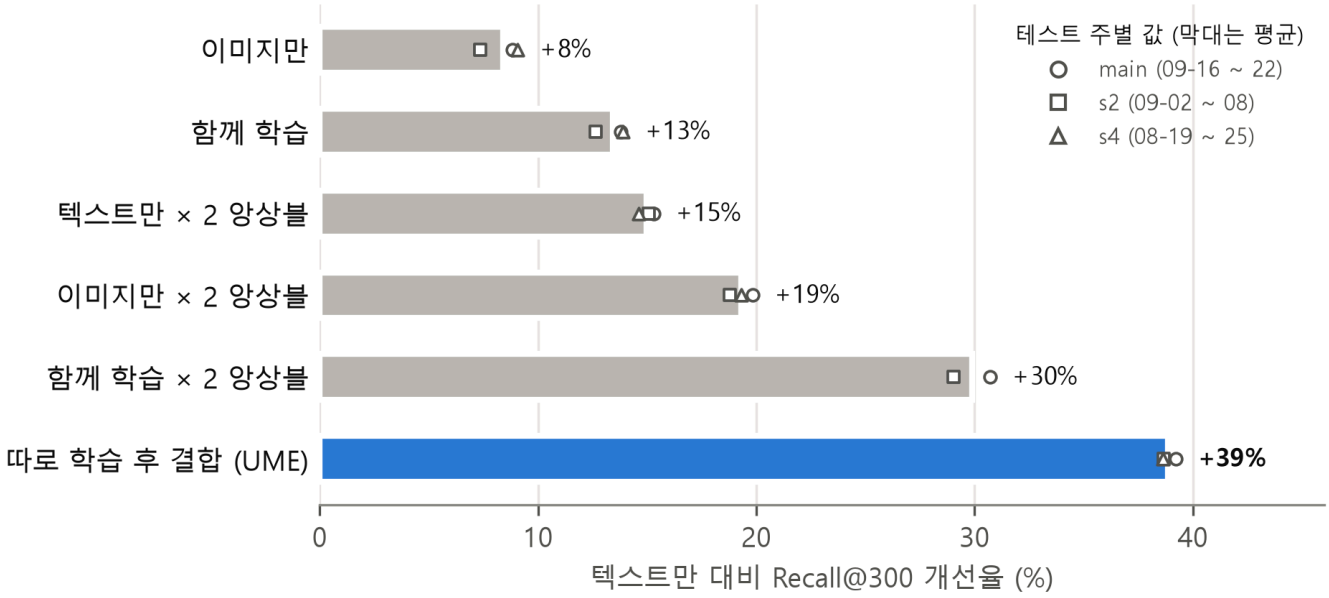


그림 2. 이미지 사용 방식별 텍스트만 대비 Recall@300 개선율. 막대는 세 테스트 주의 평균, 표시는 주별 값이다(함께 학습 × 2 앙상블은 main · s2 두 주). 이미지 인코더는 Marqo-FashionSigLIP.

5.1 함께 학습은 이미지를 충분히 쓰지 못한다

함께 학습한 모델은 이미지만 쓴 모델보다 4 ~ 5%만 높았고, 텍스트만 쓴 모델 두 개를 합친 앙상블과 비슷했다(표 1). 같은 모델로 학습에 포함된 마지막 주를 다시 채점하면, 함께 학습 모델은 그 주의 R이 테스트 주보다 0.059 높아 텍스트만(0.039) · 이미지만(0.035) 모델보다 학습 데이터에 더 맞춰져 있었다(s4, 탐색). 텍스트와 이미지를 이어 붙인 입력은 상품마다 더 고유해져, 모델이 이를 일반화보다 기억에 쓰는 경향이 있는 것으로 보인다.

5.2 따로 학습해 결합하면 크게 나아진다

텍스트만 · 이미지만 모델을 따로 학습해 결합하면 세 테스트 주 모두 텍스트만 대비 약 +39%로, 함께 학습(+13 ~ 14%)의 약 3배였다(표 1, 그림 2). 새 테스트 주 s4에서 사전 등록한 검정에서 UME는 함께 학습 모델보다 +0.0210(98.33% 구간 [+0.0197, +0.0224]) 높았다.

UME는 모델이 두 개이므로 앙상블 효과를 분리해야 한다. 이 결과를 본 뒤 공정성 대조를 사전 등록해 s2에서 검정했다. UME는 모델 수를 맞춘 함께 학습 × 2 앙상블보다 **+0.0080** ([+0.0066, +0.0096]), 가장 강한 같은 모달리티 조합인 이미지만 × 2 앙상블보다 **+0.0165** ([+0.0151, +0.0178]) 높았다(98.33%). main에서도 각각 +0.0079, +0.0180으로 재현됐다. 서로 다른 이미지 인코더 두 개(Marqo + ResNet-50)를 결합한 경우도 0.1030으로 UME(0.1177)보다 낮았다(s4, 탐색). 따라서 UME 이득의 일부는 앙상블 효과지만, 그보다 큰 부분은 텍스트와 이미지를 따로 학습한 데서 오는 보완 효과다. 가중치는 1:1이 0.5 · 2보다 두 주 모두 높았다(탐색).

5.3 어떤 이미지 인코더를 쓸까

출발점이 같은 범용 · 패션 적응 인코더 두 쌍(SigLIP 대 Marqo, LAION CLIP 대 FashionCLIP 2.0)에서 패션 적응은 이미지 기여를 바꾸지 않았다(사전 등록, 섞은 이미지 대비 상대 기여도 차이 +0.001 · +0.003, 불지지). 반면 구조가 같은 CLIP ViT-B/32에서 사전학습 데이터를 OpenAI에서 LAION-2B로 바꾸면 이미지의 상대 기여도가 0.105에서 0.212로 약 2배가 됐다(s2 사전 등록, 차이 +0.106 [+0.080, +0.131]). UME에서도 범용 SigLIP(0.1145)과 Marqo(0.1151)는 같았고 ResNet-50(0.1038)은 낮았다(s2, 탐색). 텍스트와 함께 대규모로 사전학습한 범용 인코더면 충분하다.

5.4 어디에서 이미지가 중요한가

구매 기록이 적은 희소 상품에서 이미지의 절대 기여도는 기존 상품의 약 2배였다(s2 사전 등록, 차이 +0.0129 [+0.0073, +0.0178]). UME의 이득은 주로 기존 상품에서 나왔고(s2, 텍스트만 대비 +0.033, 함께 학습 +0.009), 신규 상품에서는 오히려 함께 학습 × 2 앙상블이 더 높았다(+0.032 대 +0.024, 탐색).

5.5 강한 단순 베이스라인과의 결합

고객의 최근 구매와 직전 1주 인기 상품으로 만든 베이스라인(B2)은 s2 · main에서 0.257로 모든 콘텐츠 모델보다 높다. B2의 앞 200개에 모델 후보를 이어 붙이면 UME가 함께 학습 모델보다 +0.0097 높았다(s2 사전 등록 [+0.0088, +0.0107]). B2의 앞 280개를 두고 마지막 20자리만 UME 후보로 채우면 s4에서 B2보다 **+0.0091** 높았고(사전 등록, 97.5% 구간 [+0.0081, +0.0101]), s2 · main에서도 +0.0027 · +0.0068로 세 주 모두 베이스라인을 넘었다. 같은 20자리를 함께 학습 모델로 채우면 세 주 모두 약 0.004 낮았다. 20자리를 희소 · 신규 상품 전용으로 쓰면 전체 R은 B2보다 낮았지만(s4 −0.0035, 불지지) 신규 상품 재현율은 +0.033, 희소 상품은 +0.028 올라, 신상품 노출을 중시하는 서비스에서 선택할 만한 트레이드오프를 보였다.

5.6 효과가 없거나 불안정한 처방

표 2. 한 모델 안에서 이미지 활용을 높이려는 처방의 결과 (함께 학습 모델 대비 R 차이)

처방	테스트 주	차이	판정
텍스트 드롭아웃 (p = 0.1)	main → s2	+0.0019 → −0.0010	확증 → **재현 실패**
이미지 드롭아웃 (p = 0.3, Marqo)	s2 → s4	+0.0023 → +0.0002	확증 → **재현 실패**
이미지 드롭아웃, 인코더 4종 평균	s4	+0.0004 [−0.0002, +0.0010]	불지지
이미지 잡음 (σ = 0.06)	s4	+0.0008 [−0.0005, +0.0020]	불지지
게이트 결합	main	+0.0005 [−0.0007, +0.0018]	불지지
우세 모달리티 억제 (이미지 우세 SigLIP − 텍스트 우세 ResNet의 드롭아웃 효과)	s2	−0.0015 [−0.0031, −0.0000]	불지지 (반대 방향)

모달리티 불균형 연구의 처방을 한 모델 안에 적용한 시도는 어느 것도 두 테스트 주에서 일관된 이득을 주지 못했다(표 2). 이미지 드롭아웃은 우세 모달리티와 무관하게 일부 주에서 도움이 됐지만 효과가 작고 주에 따라 달랐다. 이 밖에 패턴 상품에서의 이미지 기여 증가와 상품 ID의 가림 효과도 사전 등록 검정에서 지지되지 않았다. 학습 균형을 조절하는 것보다 **학습 자체를 분리하는 것**이 훨씬 효과적이었다.

6. 결론 및 한계

텍스트와 이미지를 한 모델로 함께 학습하면 이미지가 더하는 정보의 상당 부분을 잃는다. 각 모달리티를 따로 학습해 점수를 결합하면 텍스트만 대비 약 39% 높아지고, 이 이득은 모델 수나 같은 모달리티 앙상블로 설명되지 않는다. 멀티모달 추천에서 이미지가 거의 쓰이지 않는다는 관찰 [1]은 이미지 자체보다 함께 학습하는 방식의 한계를 반영할 수 있다. 실무적으로는 다음을 권한다.

1. 텍스트와 함께 대규모로 사전학습한 범용 이미지 인코더를 쓴다.
2. 텍스트 모델과 이미지 모델을 따로 학습해 점수를 결합한다.
3. 강한 베이스라인의 마지막 일부 자리(300개 중 20개)를 결합 후보로 채운다.

한계.

- 단일 데이터셋(H&M)과 ID 없는 Two-Tower 구조 하나로 실험했다.
- 함께 학습 모델의 규제(드롭아웃 · 가중치 감쇠 · 에폭)를 따로 튜닝하지 않았고, 결합 가중치는 1:1로 고정했다.
- Recall@300만 측정해, 상위 소수 추천의 순서 품질은 확인하지 않았다.
- 모델 단독 성능은 재구매 · 인기 베이스라인보다 낮다.
- UME는 모델이 두 개라 추론 계산이 늘어난다. 같은 구조의 고객 타워 하나는 CPU 단일 스레드에서 중앙값 약 0.1 ~ 0.3ms(ONNX · PyTorch 측정)로 작지만, 전체 상품에 대한 점수 계산과 상위 300개 선택(측정 중앙값 약 3ms)을 모델마다 해야 하므로 검색 단계 지연은 최대 약 두 배로 늘 수 있다(추정, 직접 측정하지 않음).
- 사전학습 비교의 OpenAI · LAION은 데이터 양과 구성이 함께 다르다.
- 섞은 이미지를 쓰는 기여도 측정은 텍스트를 약하게 만드는 조건에서 대조군이 상품을 외우는 데 쓰일 수 있다(탐색).

참고문헌

[1] Y. Ye 외, "Are Multimodal Embeddings Truly Beneficial for Recommendation? A Deep Dive into Whole vs. Individual Modalities," arXiv:2508.07399, 2025. (본문 확인, 게재처 【확인 필요】)

[2] W. Wang, D. Tran, M. Feiszli, "What Makes Training Multi-Modal Classification Networks Hard?," CVPR 2020. 【확인 필요】

[3] N. Wu, S. Jastrzębski, K. Cho, K. J. Geras, "Characterizing and Overcoming the Greedy Nature of Learning in Multi-modal Deep

Neural Networks," ICML 2022.【확인 필요】

[4] C. Du 외, "On Uni-Modal Feature Learning in Supervised Multi-Modal Learning," ICML 2023. (본문 일부 확인)

[5] S. Xu 외, "BalanceBenchmark: A Survey for Multimodal Imbalance Learning," arXiv:2502.10816, 2025. (본문 일부 확인, 저자 표기【확인 필요】)

[6] J. Zhang 외, "Modality-Balanced Learning for Multimedia Recommendation," ACM MM 2024. (본문 일부 확인)

[7] Z. Yuan 외, "Where to Go Next for Recommender Systems? ID- vs. Modality-based Recommender Models Revisited," SIGIR 2023.【확인 필요】

[8] Marqo, "Marqo-FashionSigLIP," Hugging Face 모델 카드. (확인 완료)

[9] P. J. Chia 외, FashionCLIP, Hugging Face 모델 카드. (확인 완료, 논문 인용 형식【확인 필요】)

[10] H&M Personalized Fashion Recommendations, Kaggle, 2022.【확인 필요: 이용 조건 · 인용 형식】

리뷰 요청 (팀 검토용, 제출본에서 삭제)

리뷰어가 집중해서 봐 줬으면 하는 것

1. **주장의 강도:** 제목과 1절이 "따로 배워야 한다"고 단정한다. 근거(공정성 대조 · 세 주 재현)에 비해 과한지, 대안 제목 "패션 추천에서 텍스트와 이미지를 어떻게 결합할 것인가"가 나은지【미정】
2. **새로움 서술:** 2절에서 UME가 Du 외 [4]의 방법임을 밝혔다. 기여를 "추천에서의 실증"으로 한정한 서술이 충분한지
3. **5.1의 해석:** "함께 학습한 입력이 더 고유해져 기억에 쓰인다"는 해석은 학습 주 재채점 결과(탐색) 하나에 기대고 있다. 본문에 둘지, 한계로 옮길지
4. **표 2:** 부정 결과를 표 하나로 압축했다. 각 처방의 설명이 부족하지 않은지
5. **분량:** A4 2단 PDF 기준 본문이 약 4쪽, 참고문헌이 5쪽까지 넘어간다(목표 3쪽). 줄일 후보: 2절 콘텐츠 기반 추천 문단, 5.3의 FashionCLIP 쌍, 5.5의 B2 200 결합 문장, 표 2를 본문 한 문단으로, 그림 1 높이 축소

리뷰 전에 보완하면 좋은 실험 (선택)

- 상위 12개 지표(Recall@12 · NDCG@12)로 표 1 재계산 — 학습 없음, 약 10분
- 규제를 검증 주에서 튜닝한 함께 학습 모델과 UME 비교 — 한계 첫 줄 해소, 약 30분

팀원 결과 반영 현황

- 김광석 ONNX 지연 시간: 6절 한계에 반영 (PR #11)
- 김광석 탐색 분석(패턴 언급 · 마스킹 · 시각 일관성) · MMR: 본문에 넣지 않음. 패턴 언급의 반대 방향 결과는 부록 후보
- 김형우 가설 A ~ D1: 결과 파일 확인 후 결정. D1(임베딩 속성 분류)이 나오면 5.3에 한 줄 추가 가능

제출 전 필수

- 【확인 필요】 인용 원문 확인 ([2] [3] [7] [10] 우선)
- 저자 소속, 학회 양식【미정】
- 모든 사전 등록 결과(지지 · 불지지 · 재현 실패)의 전체 목록을 부록 또는 저장소 링크로 공개