패션 추천에서 이미지를 어떻게 쓸 것인가: 텍스트와의 결합 방식과 이미지 인코더 선택

김유환 · 김형우 · 김광석 (서강대학교)

요약

멀티모달 추천 모델은 텍스트에 의존하고 이미지를 거의 활용하지 못한다는 보고가 있다. 본 연구는 두 질문을 다룬다. (RQ1) 텍스트와 함께 쓸 때 이미지를 어떻게 결합해야 추천 성능이 오르는가, (RQ2) 이미지를 어떤 인코더로 임베딩해야 하며 어디에서 이미지가 중요한가. H&M 구매 데이터에서 ID를 쓰지 않는 Two-Tower 모델로 비교했고, 확증 가설은 해당 비교의 결과를 보기 전에 등록해 검정했다. RQ1: 두 임베딩을 이어 붙여 한 모델로 학습하면 텍스트만 쓴 모델보다 Recall@300이 13 ~ 14% 높았고, 텍스트 · 이미지 모델을 따로 학습해 고객별 표준화 점수를 더하면 테스트 주가 다른 세 분할 모두 약 39% 높았다. 이 결합은 모델 수를 맞춘 앙상블보다도 높아 모델 수 증가만으로는 설명하기 어려웠다. RQ2: 같은 구조의 CLIP에서 사전학습 데이터를 바꾸면 이미지 기여가 약 2배가 됐지만 패션 데이터 추가 학습의 이득은 확인하지 못했고, 이미지 기여는 구매 기록이 적은 상품에서 약 2배였다. 이 결과는 하나의 데이터셋과 모델 구조에서 얻은 것이다.

1. 서론

멀티모달 추천은 상품의 이미지와 텍스트로 표현을 풍부하게 하고 신규 상품에도 대응하려 한다. 그러나 Ye 외 [1]는 멀티모달 추천 모델에서 텍스트를 제거하면 성능이 크게 떨어지지만 이미지를 제거해도 대부분 영향이 작다고 보고했다. 일반 멀티모달 학습에서도 여러 모달리티를 함께 학습하면 배우기 쉬운 쪽에 기대어 나머지가 덜 학습되는 **모달리티 불균형**이 알려져 있다 [2, 3, 4]. 그렇다면 추천에서 이미지가 덜 쓰이는 이유는 이미지 정보의 한계일 수도, 결합 방식이나 이미지 임베딩의 한계일 수도 있다.

본 연구는 이를 두 질문으로 나눈다. **RQ1(결합):** 텍스트와 함께 쓸 때 이미지를 어떤 방식으로 결합해야 성능이 오르는가. **RQ2(임베딩):** 이미지를 어떤 인코더로 임베딩해야 하며, 어떤 상품에서 이미지가 중요한가. 같은 구조의 모델로 한 요인만 바꿔 비교했다. 기여는 다음과 같다.

1. (RQ1) 이번 설정에서 텍스트 · 이미지 모델을 **따로 학습해 점수를 결합(UME [4])** 하면 함께 학습보다 크게 높았고(텍스트만 대비 +39% 대 +13 ~ 14%), 모델 수를 맞춘 앙상블과 같은 모달리티 앙상블보다도 높음을 사전 등록 검정으로 확인했다.
2. (RQ2) 이미지 인코더 6종을 비교해, 패션 적응보다 **사전학습 데이터**가 이미지 기여와 더 크게 관련되고 이미지가 **구매 기록이 적은 상품**에서 더 중요함을 보였다. 텍스트가 담은 정보에 따른 차이는 탐색 수준에서 확인되지 않았다.
3. 강한 베이스라인과의 결합과 효과가 없었던 처방을 함께 보고한다.

2. 관련 연구

Ye 외 [1]는 Amazon 데이터에서 모달리티를 하나씩 제거해 텍스트가 시각 신호를 덮는다고 해석했다. Wang 외 [2]는 멀티모달 모델이 단일 모달 모델보다 못한 경우를, Wu 외 [3]와 Du 외 [4]는 한 모달리티에 기대는 학습을 보고했고, Du 외는 모달리티별 모델을 따로 학습해 예측을 합치는 **UME**를 제안했다. 불균형 처방을 비교한 벤치마크 [5]는 어느 방법도 모든 데이터에서 우세하지 않다고 보고했고, 추천에서는 단일 모달 교사 증류 [6]가 제안됐다. 본 연구의 결합 방식은 [4]의 방법이며, 기여는 추천에서의 통제된 비교다. 상품 ID 없이 콘텐츠만 쓰는 추천 [7]처럼 신규 상품을 바로 추천할 수 있는 설정을 다룬다.

3. 방법

모델. ID 없는 Two-Tower 모델이다. 상품 타워는 콘텐츠 임베딩을, 고객 타워는 최근 구매 상품 최대 50개의 입력 평균을 MLP(은닉 512, 출력 128)에 넣고, 정규화한 내적을 점수로 배치 내 softmax로 학습한다.

결합 방식 (RQ1, 그림 1). (a) **함께 학습:** 텍스트 · 이미지 임베딩(각 256차원)을 이어 붙여 한 모델로 학습한다. (b) **따로 학습 후 결합(UME):** 텍스트 모델(T)과 이미지 모델(I)을 따로 학습하고, 고객 u의 전체 상품 점수 $s_u^m(i)$를 모델마다 $z_u^m(i) = (s_u^m(i) - \mu_u^m) / \sigma_u^m$로 표준화해 $z^T + w \cdot z^I$ ($w = 1$)의 상위 300개를 한 번에 고른다. (c) **앙상블 대조:** 같은 모델 두 개(seed만 다름)를 (b)와 같이 결합한다. 결과는 seed 42 · 43 · 44의 평균이며, UME는 같은 seed끼리(42 + 42 등), 앙상블은 (42, 43) · (43, 44) · (44, 42) 세 쌍의 평균이다.

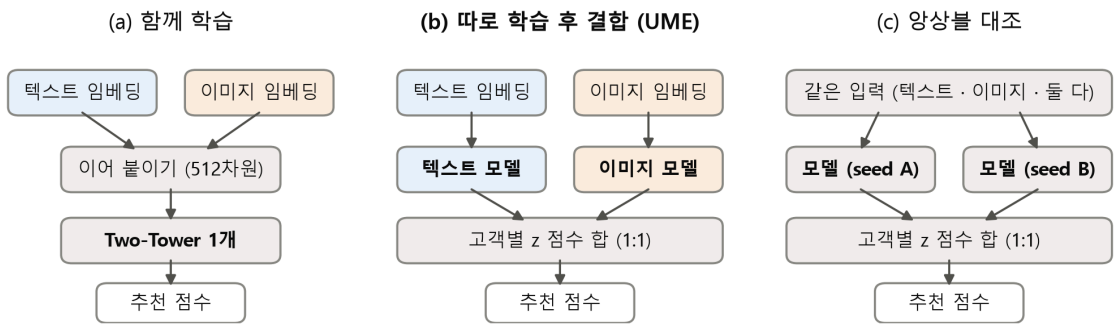


그림 1. 결합 방식. (a) 함께 학습, (b) 모달리티별로 따로 학습해 고객별 표준화 점수를 1:1로 결합(UME), (c) 모델 수 효과를 분리하기 위한 같은 모델 두 개의 결합.

이미지 임베딩과 기여도 (RQ2). 이미지 인코더만 바꾼 함께 학습 모델에서 이미지 기여도를 잰다. 같은 모델을 이미지 임베딩을 상품 간 무작위로 섞어 학습한 대조군과 비교해, 절대 기여도 = $R_{실제} - R_{섞음}$, 상대 기여도 = $(R_{실제} - R_{섞음}) / R_{섞음}$으로 정의한다.

측정과 사전 등록. 콘텐츠 모델을 후보 생성 단계로 보고 고객별 평균 Recall@300(R)을 쓰며, 학습 데이터 판매 횟수로 기존(10회 이상) · 희소(1 ~ 9회) · 신규(테스트 주 첫 판매) 상품을 나눈다. 차이는 고객 단위 짝지은 부트스트랩(1,000회)으로 구한다. 확증 가설은 판정 기준과 함께 실행 전에 저장소에 커밋했고, 등록 시점에 그 테스트 주에서 이미 본 결과를 함께 기록했다(표 3). 등록 안의 검정 수만큼 본페로니 보정해 구간 하한이 0보다 크면 지지로 판정했고, 그 밖의 비교는 탐색 결과로 95% 구간만 보고한다.

4. 실험 설정

H&M 구매 기록 31,788,324건 [10]에서 이미지가 있는 상품 53,232개와 학습 기간 구매 5회 이상 고객을 썼다. 학습 26주 · 검증 1주 · 테스트 1주로 나누고 테스트 주를 2주씩 옮긴 세 분할을 썼다: main(2020-09-16 ~ 22, 고객 46,054명), s2(09-02 ~ 08, 50,904명), s4(08-19 ~ 25, 49,061명). 세 분할은 학습 기간이 대부분 겹치므로 독립된 재현이 아니라 테스트 주를 바꾼 반복으로 본다. 텍스트는 all-MiniLM-L6-v2(상품명 · 품목 · 색상 · 설명), 이미지는 Marqo-FashionSigLIP [8]을 기본으로 하고 표 2의 인코더를 비교했으며, 모두 PCA 256차원 + L2 정규화했다. 학습률 0.0005, 8에폭, 배치 2,048, 온도 0.05(검증 주로 선택)이며, 같은 조건의 재학습 22회가 모두 같은 추천을 내 학습이 결정적임을 확인했다.

표 1. RQ1 결합 방식별 Recall@300 (seed 3개 평균, 괄호는 텍스트만 대비). 이미지는 Marqo-FashionSigLIP, s4의 함께 학습 × 2는 미계산.

방식	모델 수	main	s2	s4
텍스트만	1	0.0928	0.0830	0.0849
이미지만	1	0.1010 (+9%)	0.0891 (+7%)	0.0926 (+9%)
함께 학습	1	0.1056 (+14%)	0.0935 (+13%)	0.0967 (+14%)
텍스트만 × 2 앙상블	2	0.1070	0.0955	0.0973
이미지만 × 2 앙상블	2	0.1112	0.0986	0.1013
함께 학습 × 2 앙상블	2	0.1213	0.1071	—
따로 학습 후 결합 (UME)	2	**0.1292 (+39%)**	**0.1151 (+39%)**	**0.1177 (+39%)**

5. 결과: 결합 방식 (RQ1)

5.1 함께 학습의 이득은 작았다. 이미지만 쓴 모델은 세 분할 모두 텍스트만보다 7 ~ 9% 높아 이미지 자체에 쓸 만한 정보가 있었다. 그러나 함께 학습은 이미지만보다 4 ~ 5% 높은 데 그쳤고 텍스트 모델 두 개의 앙상블과 비슷했다(표 1). 가능한 해석의 하나로, 학습 마지막 주를 다시 채점하면 함께 학습은 테스트 주보다 R이 0.059 높아 단일 모달 모델(0.035 ~ 0.039)보다 학습 데이터에 더 맞춰져 있었다(s4, 탐색). 이것만으로 원인을 확정할 수는 없다.

5.2 따로 학습해 결합하면 높았다. UME는 세 분할 모두 텍스트만 대비 약 +39%였다(표 1). 새 분할 s4의 사전 등록 검정에서 UME는 함께 학습보다 +0.0210 [+0.0197, +0.0224] 높았다. 이어 s2에서 모델 수를 맞춘 함께 학습 × 2보다 **+0.0080** [+0.0066, +0.0096], 가장 강한 같은 모달리티 조합인 이미지 × 2보다 **+0.0165** [+0.0151, +0.0178] 높았고(사전 등록, 98.33%), main에서도 +0.0079 · +0.0180이었다(탐색). 두 이미지 인코더의 결합(Marqo + ResNet-50, 0.1030)도 UME(0.1177)보다 낮았고(s4), 가중치 w는 0.5 · 1 · 2 중 1이 s2 · main 모두 가장 높았다(탐색). 따라서 UME의 이득은 단순한 모델 수 증가만으로는 설명하기 어렵다. UME의 이득은 주로 기존 상품에서 났고, 신규 상품에서는 함께 학습 × 2가 더 높았다(s2, 텍스트만 대비 +0.032 대 +0.024, 탐색).

5.3 강한 베이스라인과의 결합. 재구매 + 인기 베이스라인(B2)은 모든 콘텐츠 모델보다 높다(s2 · main 0.257, s4 0.208). B2 앞 280개에 UME 후보 20개를 붙이면 s4에서 B2보다 **+0.0091** [+0.0081, +0.0101] 높았고(사전 등록, 97.5%) s2 · main에서도 +0.0027 · +0.0068이었다(탐색). 같은 자리를 함께 학습 후보로 채우는 것보다도 UME 후보가 높았다(B2 200 + 후보, s2 사전 등록 +0.0097 [+0.0088, +0.0107], 98.33%). 20자리를 희소 · 신규 상품 전용으로 쓰면 전체는 B2보다 낮았지만(s4 사전 등록, −0.0035) 신규 상품 재현율은 +0.033 올랐다.

5.4 한 모델 안의 균형 처방. 텍스트 · 이미지 드롭아웃, 이미지 잡음, 게이트 결합, 우세 모달리티 억제를 사전 등록 8건으로 검정했다. 3건은 처음 주에서 작은 이득(+0.0018 ~ +0.0023)을 보였으나 그중 2건은 다른 주에서 재현되지 않았고, 5건은 지지되지 않았다(전체 결과는 저장소 공개). 이번 설정에서는 한 모델 안에서 균형을 조절하는 것보다 학습을 분리하는 쪽이 효과가 컸다.

표 2. RQ2 이미지 인코더별 상대 기여도 (main, 함께 학습, seed 3개 평균; 패션 적응 비교만 사전 등록, 나머지는 탐색). → 패션: 패션 데이터로 추가 학습.

이미지 인코더	사전학습 데이터	패션 적응	전체	기존 상품	희소 상품	신규 상품
ResNet-50	ImageNet	×	0.090	0.079	0.302	0.392
OpenAI CLIP B/32	OpenAI 이미지-텍스트	×	0.092	0.076	0.468	0.578
LAION CLIP B/32	LAION-2B	×	0.179	0.157	0.494	0.782
FashionCLIP 2.0 [9]	LAION-2B → 패션	○	0.182	0.162	0.572	0.784
범용 SigLIP B/16	WebLI	×	0.186	0.165	0.655	0.774
Marqo-FashionSigLIP [8]	WebLI → 패션	○	**0.187**	**0.167**	**0.635**	**0.744**

6. 결과: 이미지 임베딩 (RQ2)

6.1 사전학습 데이터가 패션 적응보다 중요했다. 인코더는 두 층으로 나뉘었다(표 2). 출발점이 같은 범용 · 패션 적응 인코더 두 쌍에서 패션 적응의 추가 이득은 확인하지 못했다(Marqo − SigLIP +0.0014 [−0.0218, +0.0237], 사전 등록 불지지; FashionCLIP − LAION CLIP +0.0026). 반면 구조가 같은 CLIP B/32에서 사전학습 데이터를 OpenAI에서 LAION-2B로 바꾸면 상대 기여도가 약 2배였다(표 2; s2 사전 등록 0.105 → 0.212, +0.106 [+0.080, +0.131]). 다만 두 데이터는 양과 구성이 함께 달라 원인을 하나로 특정할 수 없다. UME에서도 범용 SigLIP(0.1145)과 Marqo(0.1151)의 차이는 확인되지 않았고 ResNet-50(0.1038)은 낮았다(s2, 탐색).

6.2 이미지는 구매 기록이 적은 상품에서 중요했다. 모든 인코더에서 희소 · 신규 상품의 상대 기여도가 기존 상품의 2배 이상이었다(표 2). Marqo의 절대 기여도는 희소 상품이 기존 상품의 약 2배였다(s2 사전 등록, +0.0129 [+0.0073, +0.0178]).

6.3 텍스트가 담은 정보와 이미지 기여 (탐색). 이미지가 텍스트에 없는 정보를 채운다면, 설명에 패턴이 언급되지 않은 패턴 상품에서 이미지 기여가 더 커야 한다. main에서 같은 품목 안에서 이미지를 섞은 대조군 대비 기여도(구매 건 기준)를 비교하자 오히려 언급 상품에서 컸다(미언급 − 언급 −0.0131 [−0.0205, −0.0063], 상품군 4개 · seed 3개 모두 같은 방향). 같은 상품의 텍스트에서 패턴 단어를 [MASK]로 가리고 다시 학습해도 기여도 증가는 확인하지 못했고(+0.0033 [−0.0011, +0.0074]), 시각적으로 일관된 구매 이력을 가진 고객의 이미지 이득이 더 크다는 차이도 확인하지 못했다(+0.0066 [−0.0099, +0.0226]). 이번 설정에서는 이미지가 텍스트의 빈칸을 채운다는 근거를 찾지 못했다. 세 분석은 대조군과 집계 방식이 표 2와 다르다.

표 3. 사전 등록한 확증 검정 전체. 등록 커밋 이후 학습 · 분석을 실행했다.

가설	등록일 (커밋)	검정 주	등록 시 그 주에서 이미 본 결과	판정
패턴 > 무지 상품 이미지 기여	09-28 (99e32c6)	main	없음	불지지
패션 적응 > 범용 · ID 가림 (RQ2)	09-29 (009c592)	main	Marqo 함께 학습 모델 (1차)	불지지 · 불지지
사전학습 데이터 · 희소 상품 (RQ2)	10-14 (da3a512)	s2	함께 학습의 구간별 R (4차). 가설은 main 사후 결과로 설정	지지
한 모델 안의 처방 8건	10-14 ~ 10-19	main · s2 · s4	각 등록 파일에 기록	지지 3 (재현 실패 2) · 불지지 5
UME > 함께 학습 (RQ1)	10-19 (1fac6ec)	s4	없음 (새 분할)	지지
UME > 앙상블 · 결합 후보 (RQ1)	10-19 (b7e994a)	s2	단일 모델 · B2 결합 (UME · 앙상블 미계산)	지지
B2 + UME 20자리 / 신규 전용	10-19 (4d04420)	s4	UME 단독 (자리 수는 s2 · main 탐색으로 정함)	지지 / 불지지

7. 결론 및 한계

이번 H&M · Two-Tower 설정에서 텍스트와 이미지를 한 모델로 함께 학습하는 것보다 모달리티별로 따로 학습해 점수를 결합하는 방식이 텍스트만 대비 약 39%로 더 높았고, 이 차이는 모델 수 증가만으로는 설명하기 어려웠다(RQ1). 이미지 인코더는 패션 적응 여부보다 사전학습 데이터와 더 크게 관련됐고, 이미지는 구매 기록이 적은 상품에서 더 중요했지만 텍스트가 이미 담은 정보에 따른 차이는 확인하지 못했다(RQ2). 이미지가 거의 쓰이지 않는다는 관찰 [1]은 이미지 자체보다 결합 방식과 인코더 선택의 영향을 받을 수 있다.

한계. 데이터셋과 모델 구조가 하나이고, 세 분할은 학습 기간이 겹친다. 함께 학습 모델의 규제를 따로 튜닝하지 않았고 결합 가중치는 세 값만 비교했다. Recall@300만 측정했고 모델 단독 성능은 베이스라인보다 낮다. 임베딩은 인코더만 비교했고 차원 · 전처리 · 미세조정은 다루지 않았다. UME의 추론 지연 시간은 직접 측정하지 않았다. 코드, 사전 등록 파일과 모든 검정 결과는 저장소에 공개한다【미정: 링크】.

참고문헌

[1] Y. Ye 외, "Are Multimodal Embeddings Truly Beneficial for Recommendation? A Deep Dive into Whole vs. Individual Modalities," arXiv:2508.07399, 2025.

[2] W. Wang, D. Tran, M. Feiszli, "What Makes Training Multi-Modal Classification Networks Hard?," CVPR 2020.【확인 필요】

[3] N. Wu, S. Jastrzębski, K. Cho, K. J. Geras, "Characterizing and Overcoming the Greedy Nature of Learning in Multi-modal Deep Neural Networks," ICML 2022.【확인 필요】

[4] C. Du 외, "On Uni-Modal Feature Learning in Supervised Multi-Modal Learning," ICML 2023.

[5] S. Xu 외, "BalanceBenchmark: A Survey for Multimodal Imbalance Learning," arXiv:2502.10816, 2025.

[6] J. Zhang 외, "Modality-Balanced Learning for Multimedia Recommendation," ACM MM 2024.

[7] Z. Yuan 외, "Where to Go Next for Recommender Systems? ID- vs. Modality-based Recommender Models Revisited," SIGIR 2023.【확인 필요】

[8] Marqo, "Marqo-FashionSigLIP," Hugging Face, 2024.

[9] P. J. Chia 외, "FashionCLIP," Hugging Face.【확인 필요: 인용 형식】

[10] H&M Personalized Fashion Recommendations, Kaggle, 2022.【확인 필요: 이용 조건】